密瓜智能 DYNAMIA.AI | HAMi

密瓜智能 & HAMi

用户案例集



HAMi 原厂团队，让异构算力按业务需要分配

目录

从业务任务看算力价值

01 金融 / 银行 / 证券

02 教育 / 科研 / 医药

03 汽车 / 自动驾驶

04 互联网 / AI 平台

05 物流

06 政企 / 能源 / 电力

07 云厂商 / 算力云

密瓜由 HAMi 发起人和核心维护者创立

密瓜智能 DYNAMIA.AI | HAMi

创始团队



张 潇
创始人兼 CEO
HAMi Maintainer



李孟轩
联合创始人兼 CTO
HAMi 作者 / Maintainer

开源生态



宋净超 Jimmy Song
开源生态 VP
CNCF Ambassador

密瓜智能（Dynamia）由 CNCF 托管孵化项目HAMi 的发起与核心维护团队创立，致力于构建 AI 基础设施的开源内核。

围绕异构 GPU 资源虚拟化、高效调度与生产级落地，帮助企业将分散、复杂、昂贵的算力资源转化为可共享、可隔离、可按需使用的基础设施能力。

最终用户目前已超过40个国家， 300 家企业，覆盖国内主流云厂商、互联网以及 KA 用户，包括招行、银联、顺丰、蔚来、Snow、LinkedIn等 ，并已拓展至东南亚、欧洲等海外地区。

01 运行贴合业务

推理响应、模型驻留、显存增长

提供运行与显存增强，验证目标负载

02 设备适配明确

设备、驱动与交付版本一起确认

对接厂商，明确支持的设备组合

03 上线持续维护

接入、定位、修复与版本更新

客户使用的版本持续有人维护

投资方：
INVESTORS

奇绩创坛 MIRACLEPLUS　FOSUN CAPITAL 复星创富　拙朴　DaoCloud

HAMi 行业应用案例

密瓜智能 DYNAMIA.AI | HAMi

自动驾驶

Momenta

蔚来

数据处理、并发调度与仿真任务复用

文档与内容 AI

合合信息

SNOW

文档智能与图像生成服务的 GPU 共享

平台与生产服务

深信服

顺丰科技

多模型服务与资源池化

金融与 AI 一体机

招商银行

中电科云

生产服务、训练与研发的资源治理

医药与科研

复星医药

复旦大学

药物研发算力建设与高校科研训推服务

HAMi 在业务系统中承担什么

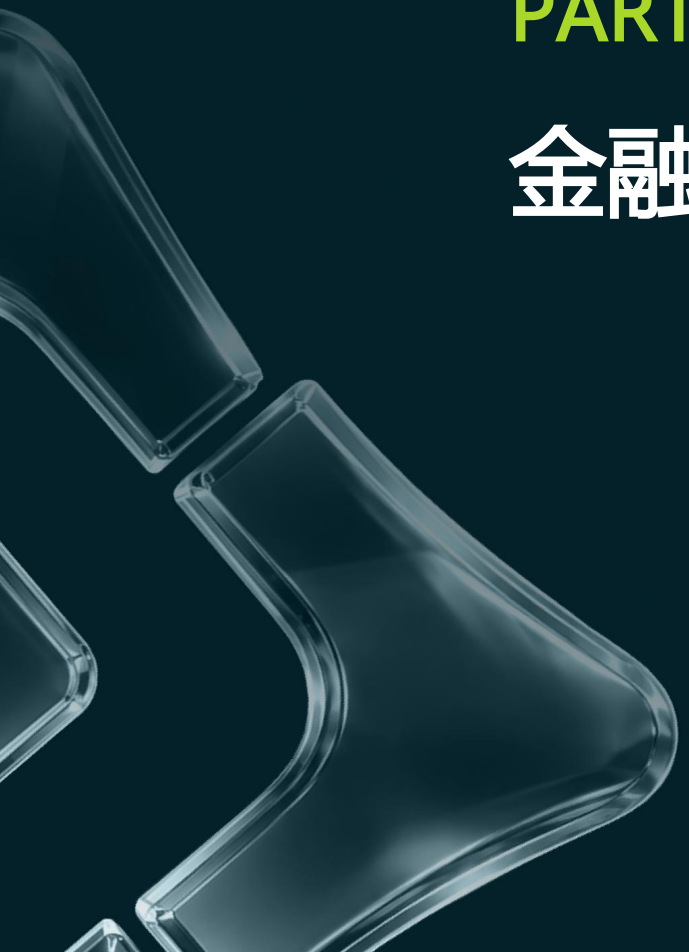
业务平台组织服务，HAMi 组织 GPU 资源。

业务应用	文档处理 / 智能问答 / 科研实验 / 自动驾驶数据
模型与任务	模型服务副本 / 训练作业 / Notebook / 批处理 Pod
平台与编排	业务路由 / 队列准入 / 扩缩容 / 权限与计量
HAMi	**设备发现 / 任务放置 / 显存与算力共享分配**
资源供给	GPU / NPU 资源池　节点　设备与运行时

密瓜智能 DYNAMIA.AI | HAMi

PART 01

金融 / 银行 / 证券



某头部银行：多路推理服务共享 GPU

某头部银行

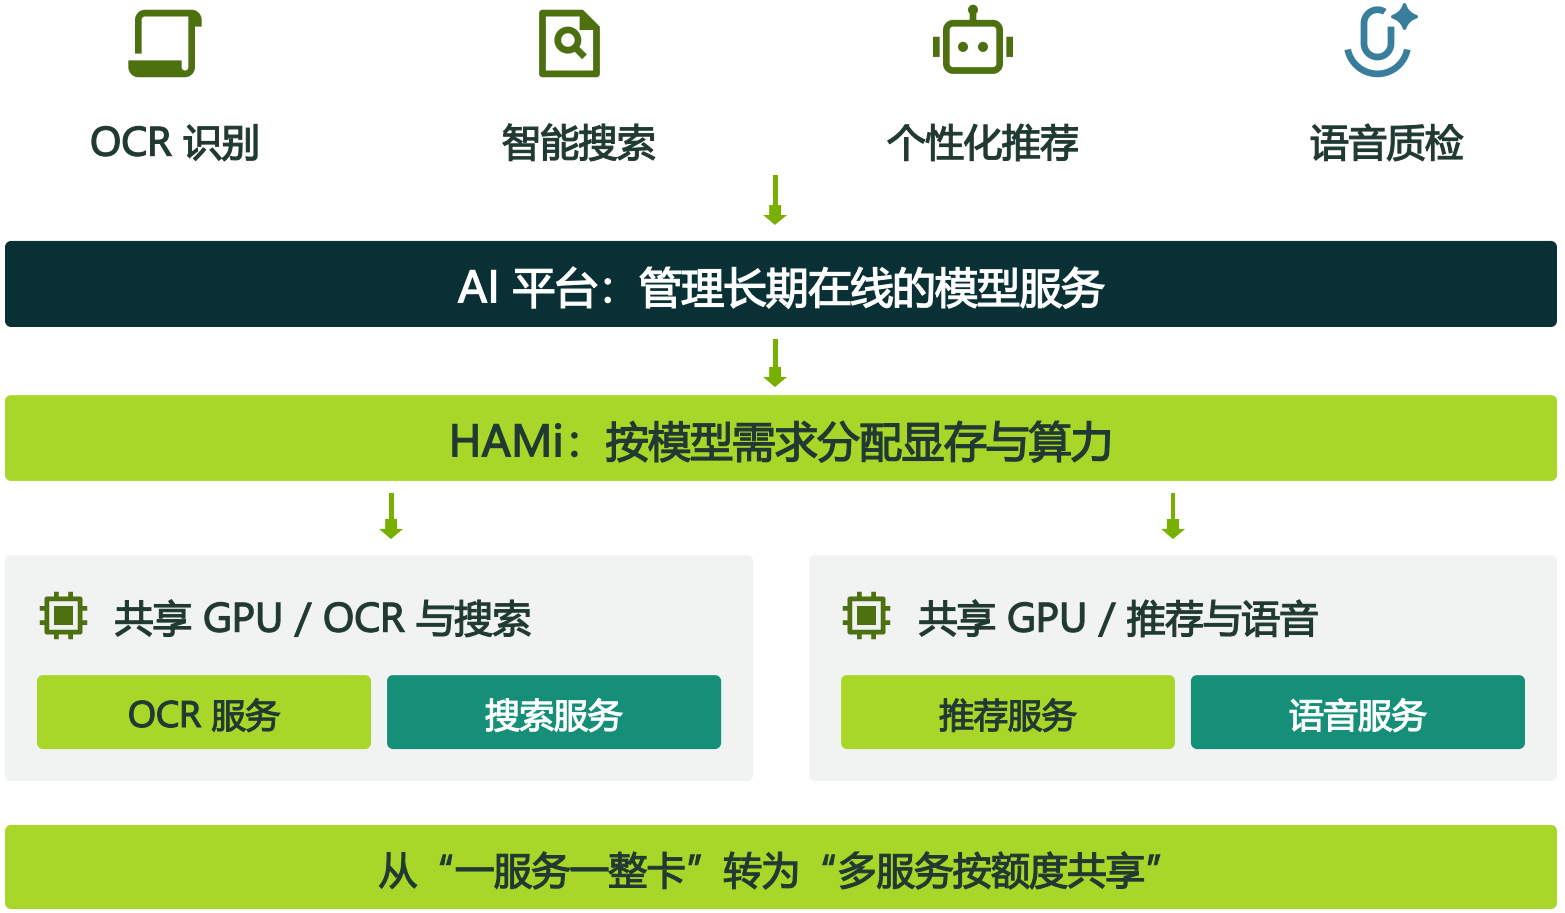
OCR、搜索、推荐与语音质检长期在线，峰值并不同步。按服务分配显存与算力，让多路模型共享已有 GPU，减少低峰时的整卡闲置。

20% → 70%

GPU 利用率

140 张 V100

70 台服务器的资源规模



招商银行：异构算力统一治理

招商银行
CHINA MERCHANTS BANK

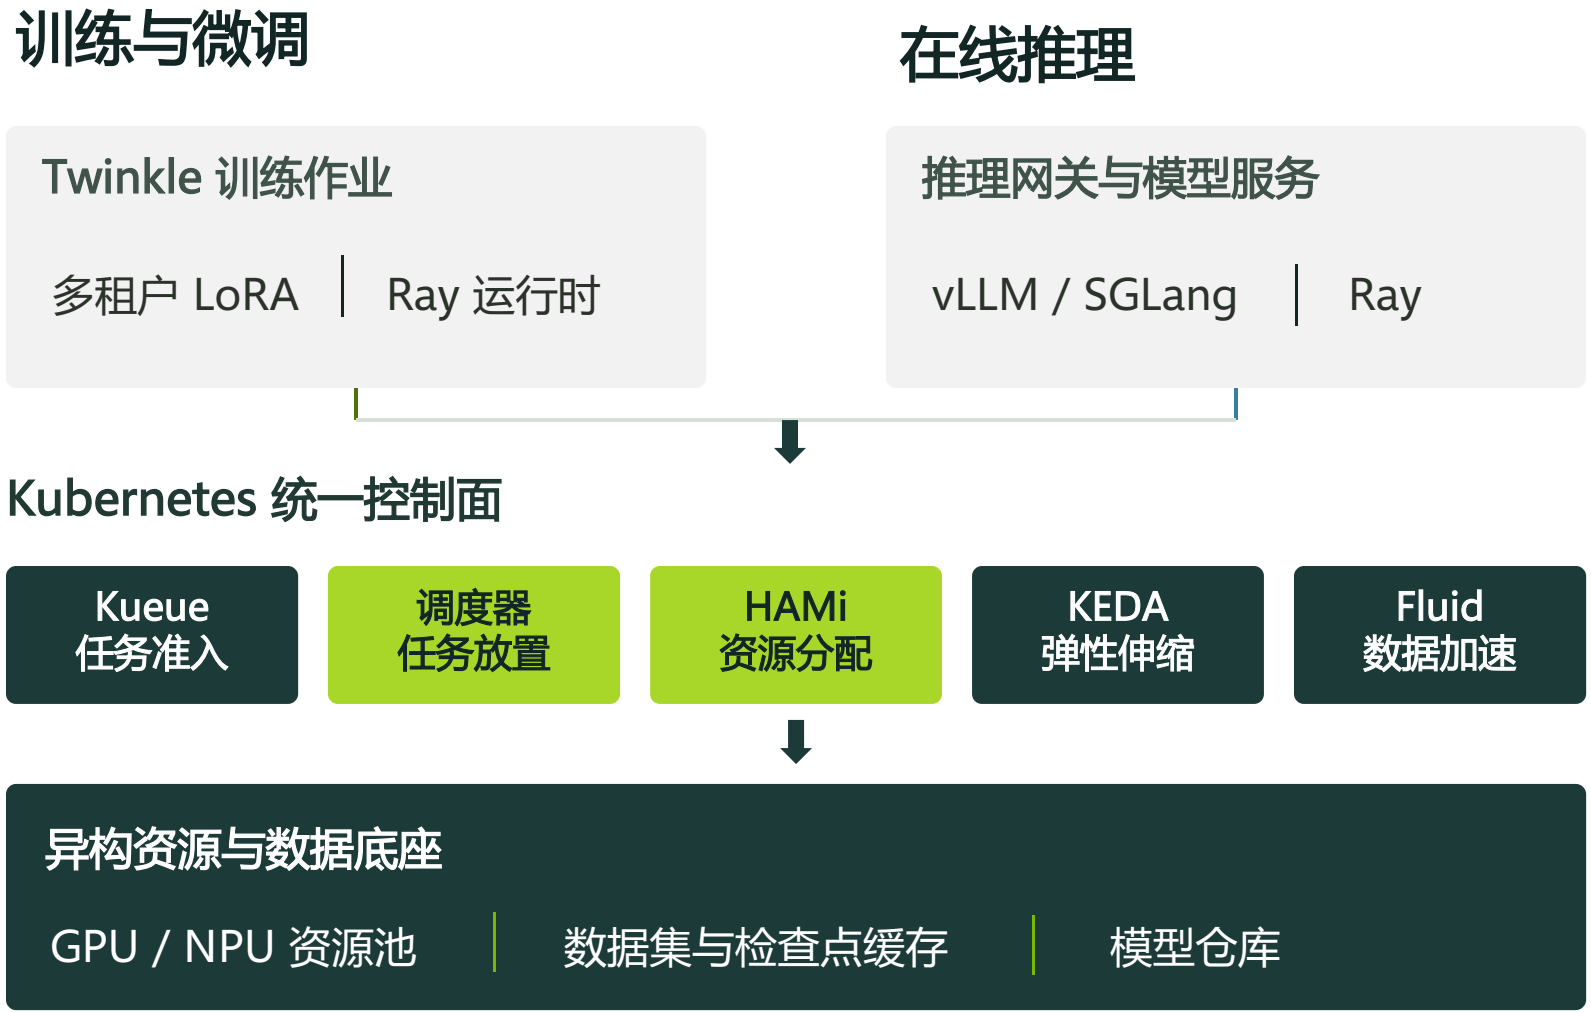
近万张异构卡支撑训推业务，
硬件和运维策略容易分散。
以统一控制面组织算力，
让共享、弹性和数据加速
共同服务内部 AI 业务。

35% → 60%+

平台平均 GPU利用率

下降 > 60%

每百万 Token 成本



某证券公司：研发 Notebook 按需共卡

某证券公司

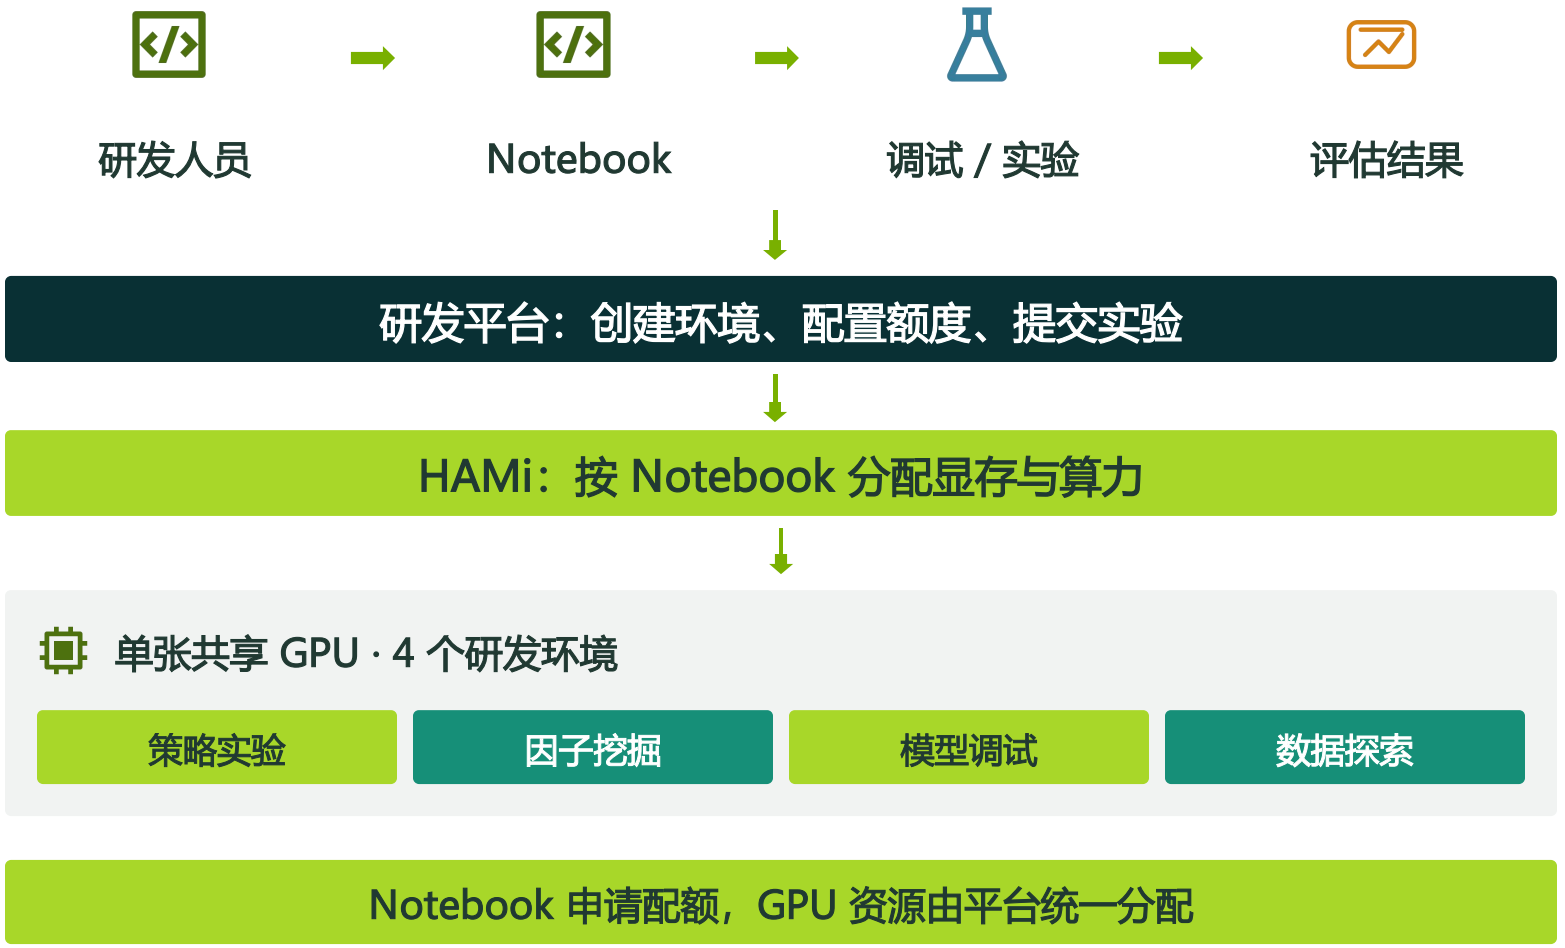
量化策略、因子挖掘与模型调试交替进行。为每个 Notebook 分配显存和算力额度，研发人员共享同卡，并行开展实验。

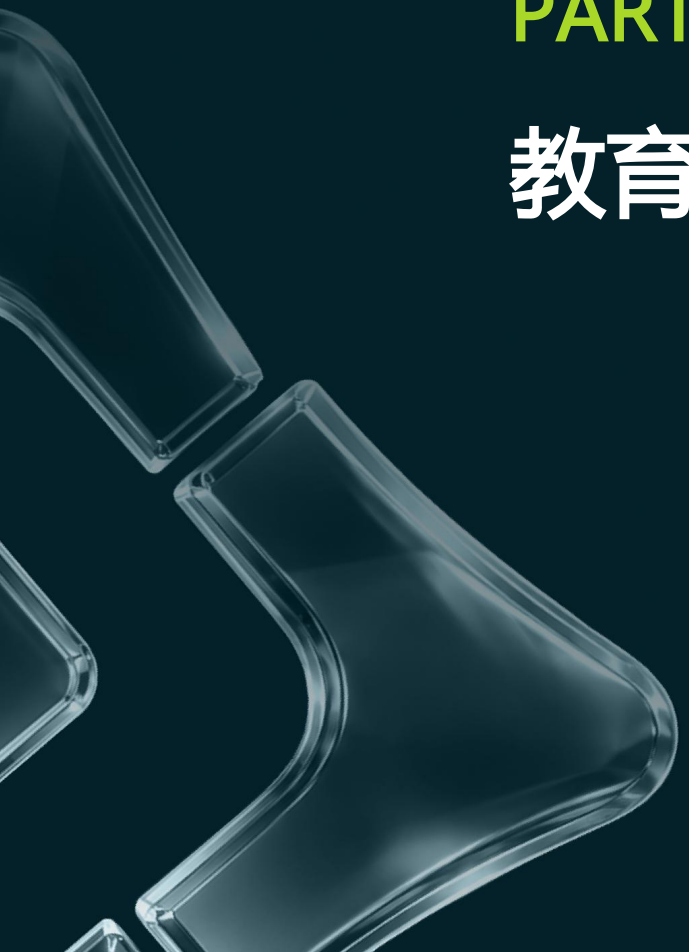
1 卡 4 人

并行研发配置

按需分配

减少小实验的整卡占用





PART 02

教育 / 科研 / 医药

上海立信：教学与科研共享算力池

上海立信会计金融学院
SHANGHAI LIXIN UNIVERSITY OF ACCOUNTING AND FINANCE

课程实验集中开课，教师科研和课后实训持续运行。教学按份额使用，科研按任务需求申请，让同一算力池服务两类工作。

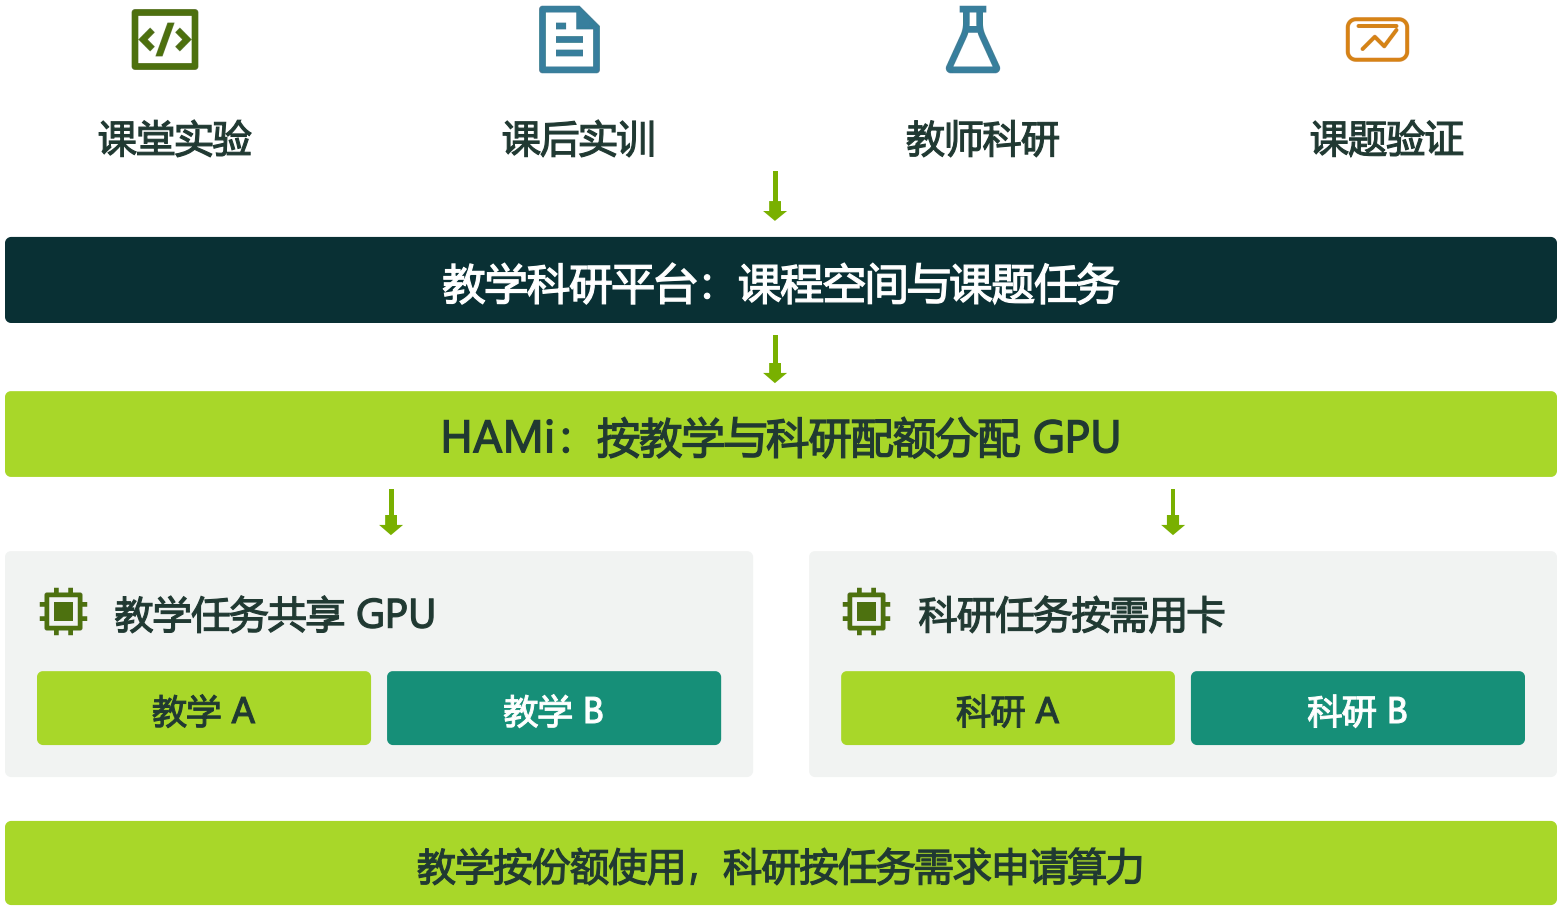
16 张 GPU

GPU 资源规模

教学 + 科研

同一算力底座服务两类任务

教学与科研任务分别提交资源需求



复星医药：药物研发算力池建设

FOSUN PHARMA
复星医药

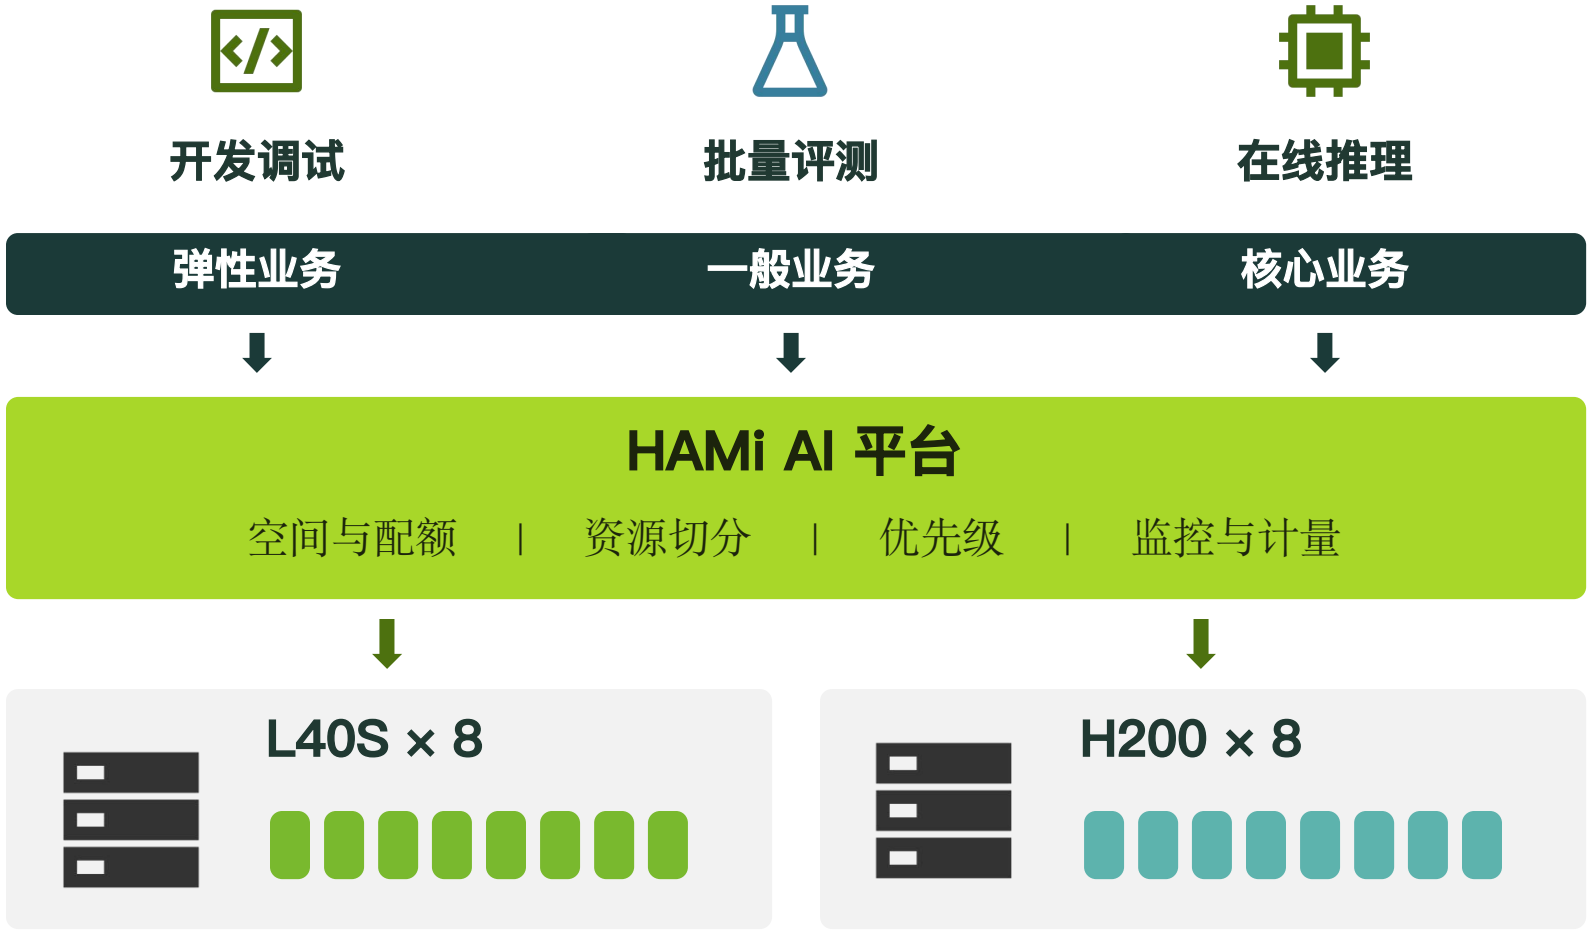
药物研发涉及多项小模型实验，单个任务难以用满大卡。以平台统一分配 GPU，按业务等级配置空间、配额与调度策略。

16 张 GPU

项目建设范围

8 × L40S
8 × H200

研发任务按业务等级使用算力



复旦大学：科研训练与推理算力服务

复旦大学 FUDAN UNIVERSITY

科研模型需要训练实验，也需要推理验证。
密瓜分别提供两类云端算力，配套虚拟化调度平台与运维，按项目周期支撑科研工作。

业务价值

按科研周期获取算力，减少自建投入。

平台、运维配套交付，科研团队专注模型实验。



PREP EDU：教育 AI 服务稳定共享 GPU

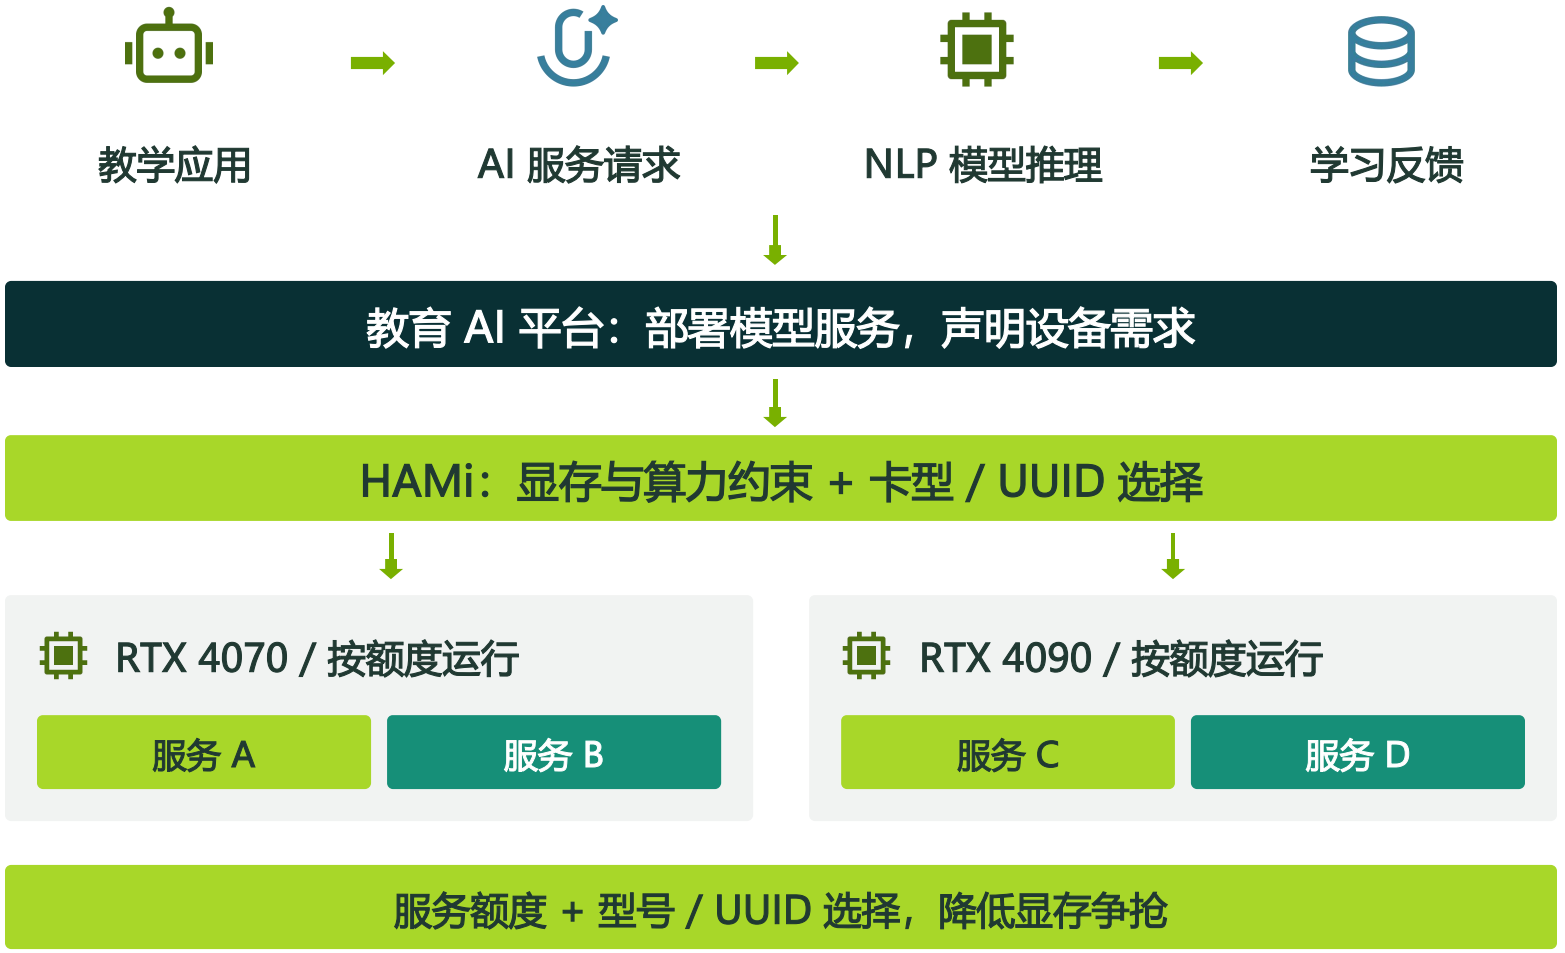
教育 AI 服务运行在 RTX 4070、4090 等混合卡型上。通过显存与算力约束、型号或 UUID 选择，减少显存争抢并统一接入新节点。

90%

GPU 基础设施由 HAMi 管理

50%

原有 GPU 管理痛点得到解决



密瓜智能 DYNAMIA.AI | HAMi

PART 03

汽车 / 自动驾驶



Momenta：自动驾驶数据处理与 GPU 共享

momenta

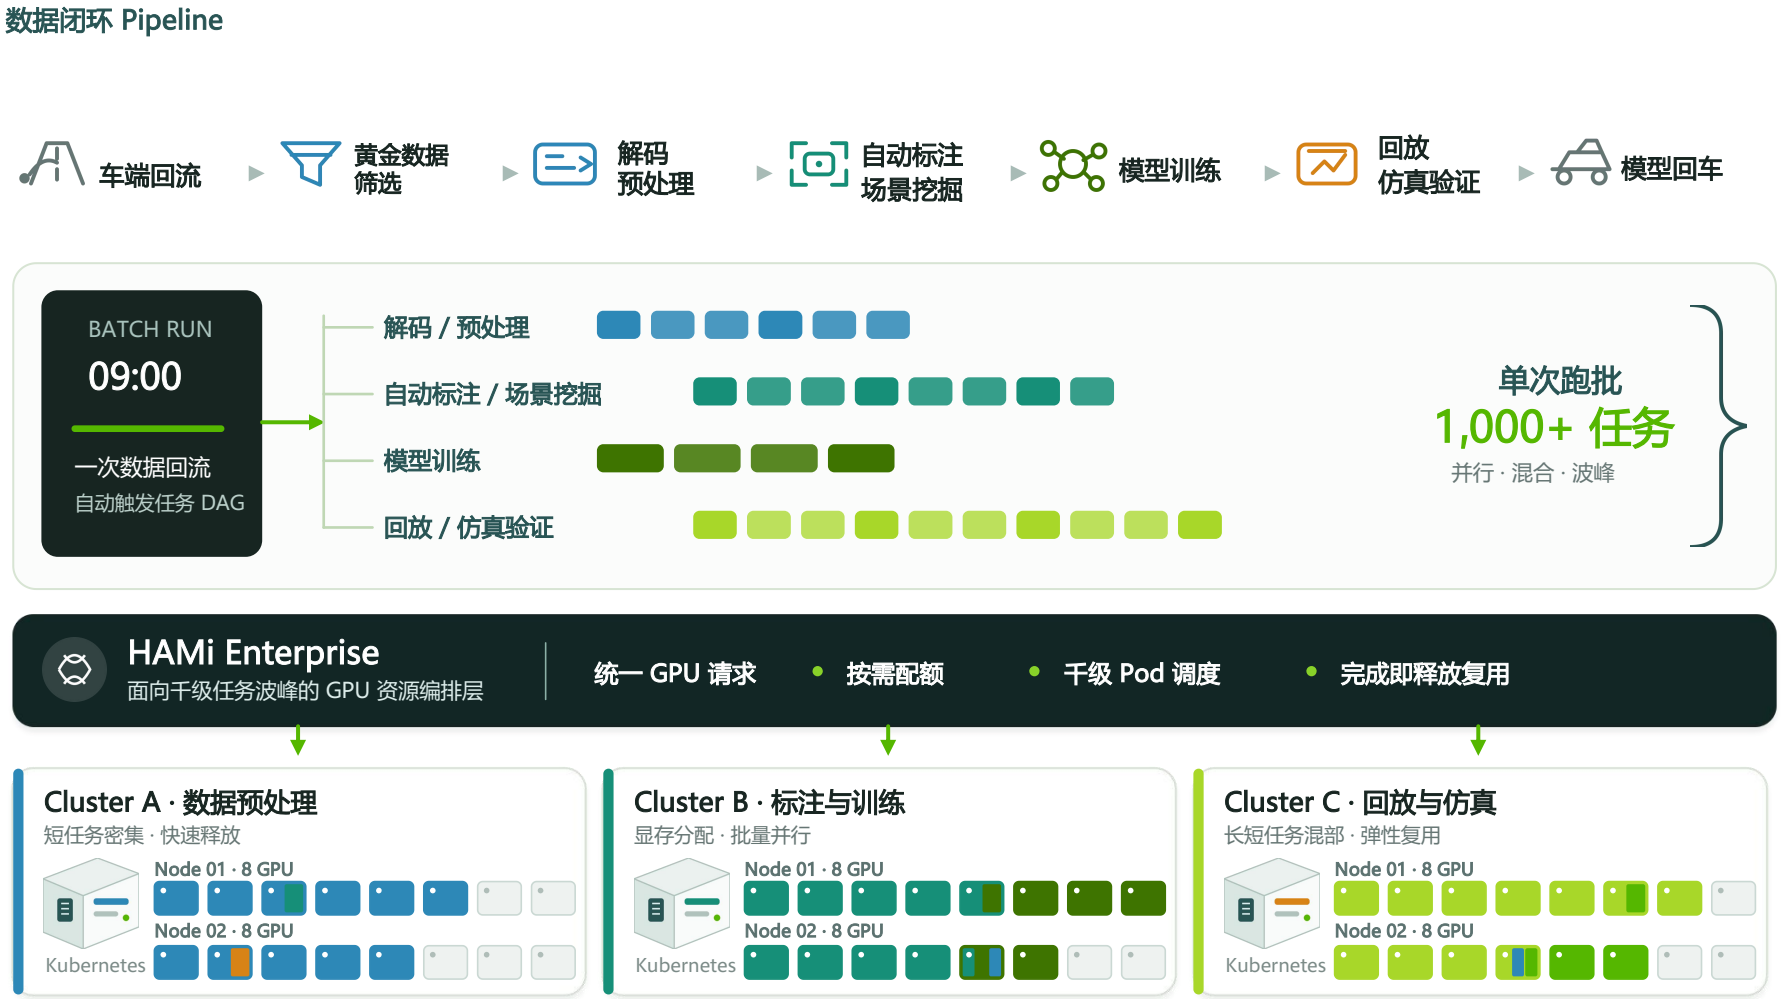
车辆回传数据需要批量预处理、标注、识别与仿真。多集群离线任务集中提交，既要共享 GPU，也要承受上千 Pod 的调度压力。

1,800 Pods

峰值调度规模

4–5 小时 → 约 10 分钟

调度调优记录



蔚来：CI 与仿真任务复用 GPU

NIO

编译、文件读取与预处理主要使用 CPU，GPU 仅在测试和仿真阶段集中运行。按工作负载选择共享机制，让适合的任务复用空闲算力。

GPU 小时 − 30%

选定仿真工作负载

3 天 → 2 天

端到端仿真任务完成时间

研发回归流程

编译 / 取文件 → CPU 预处理 → GPU 测试 / 仿真 → 结果汇总

按任务需求选择分配方式

CI / 小模型推理 / 仿真	HAMi 细粒度共享
算法开发	NVIDIA MIG
可容忍资源竞争的任务	时间切片
大规模训练	整卡资源

Kubernetes 调度与节点运行时

任务队列与策略	Device Plugin	NVIDIA A100 / A800

元戎启行：容器任务按需共享 GPU

元戎启行

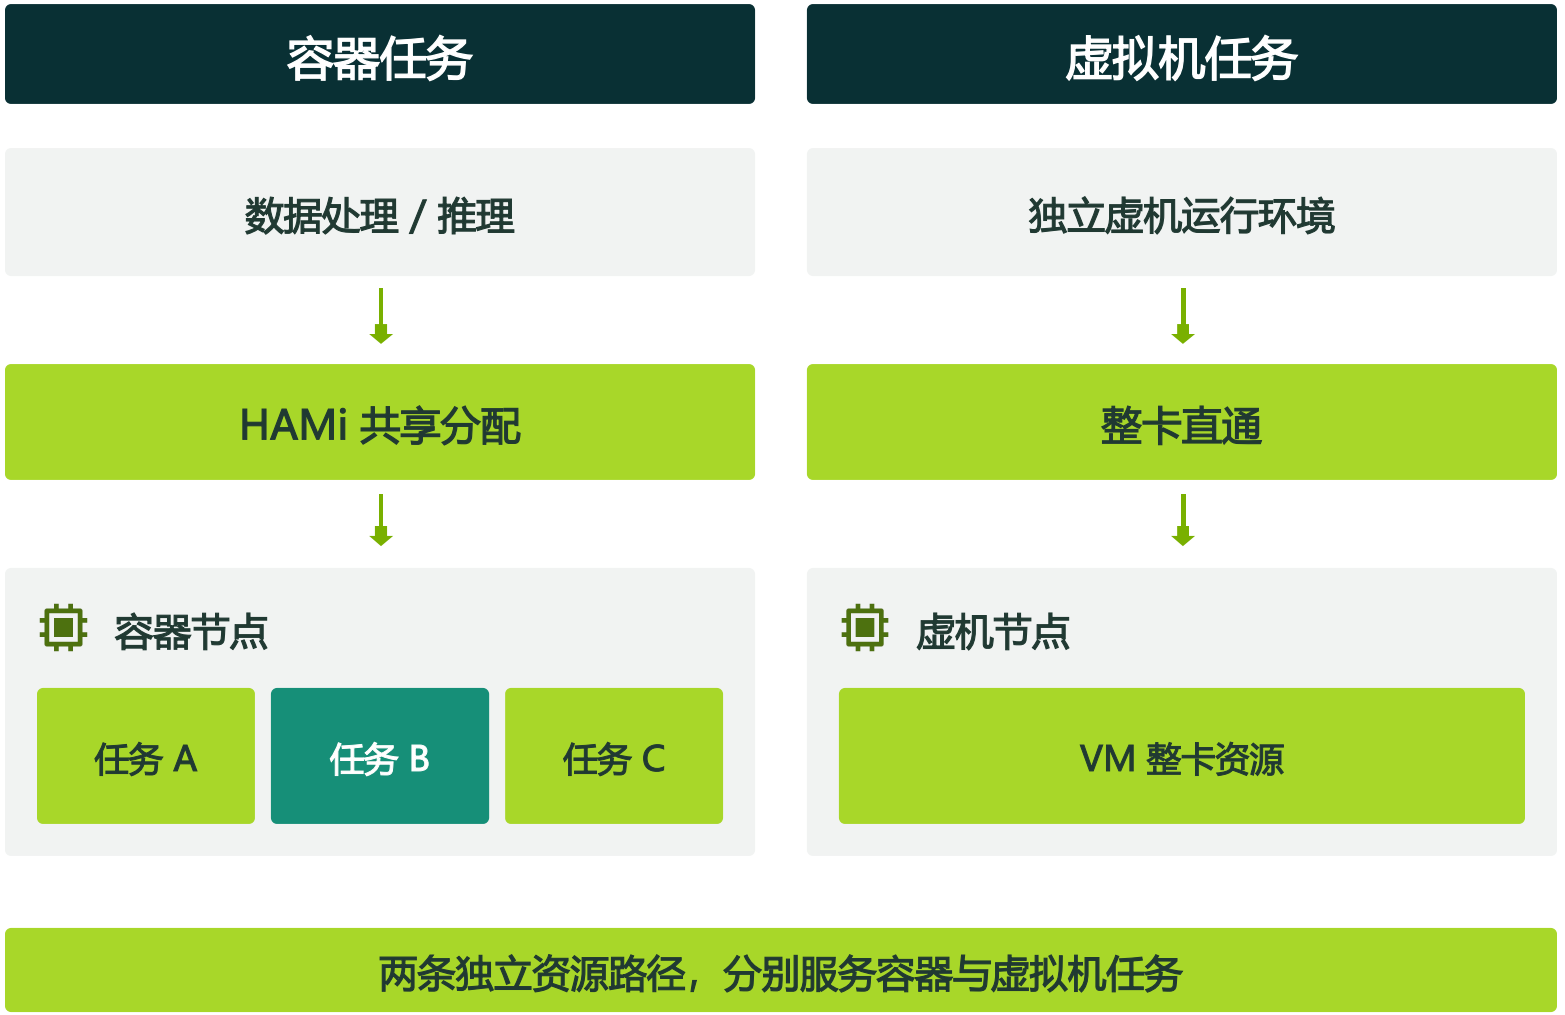
数据处理与容器推理需要细粒度共享，部分任务保留独立虚机环境。容器侧使用 HAMi 共享 GPU，虚机侧沿用整卡直通。

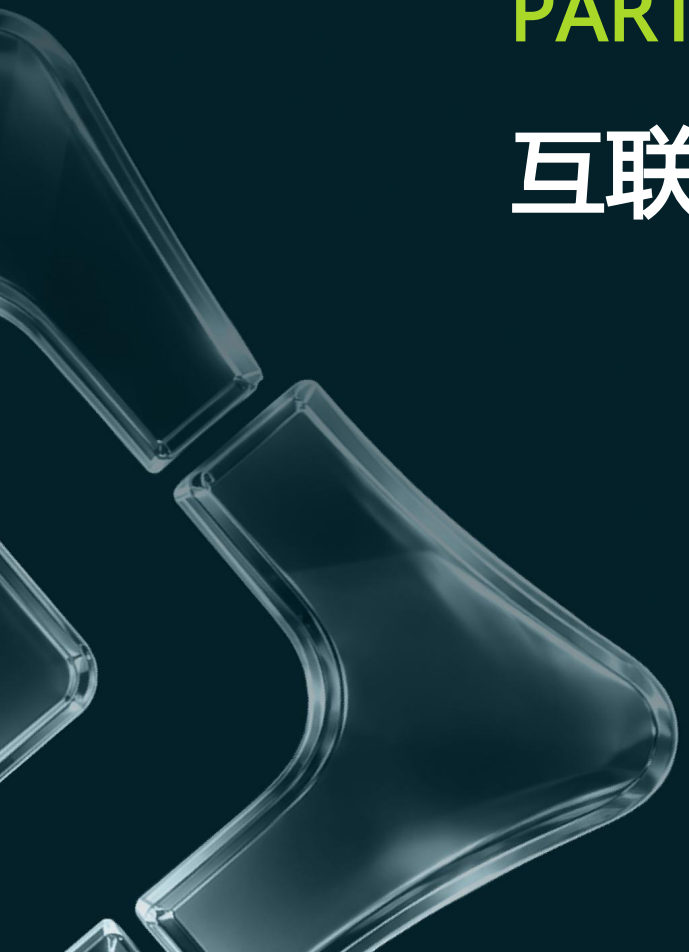
容器共享

适配中小任务的资源需求

虚机直通

保留另一类负载的运行方式





PART 04

互联网 / AI 平台

合合信息：文档智能推理与原厂技术支持

INTSIG 合合信息™

文字识别、文档解析等业务，
需要多个模型协同处理。
通过 HAMi 共享 GPU，
并由密瓜提供开源技术咨询，
支撑已有平台持续运行。

已签约

HAMi 开源技术咨询服务

700 副本 / 约 360 秒

客户多副本调度测试

文档进入，多模型协同处理



现有业务平台

共享 GPU 1

模型副本 A | 模型副本 B

共享 GPU 2

模型副本 C | 模型副本 D

密瓜原厂技术咨询

使用与配置咨询 | 问题定位建议 | 社区缺陷协同

SNOW：图像生成业务共享 GPU

SNOW Corp.

图像生成串联训练与推理，
流水线内多个容器共用 GPU。
SNOW、EPIK、B612 的业务
高峰由 KEDA 与混合云扩容，
减少长期超量预留。

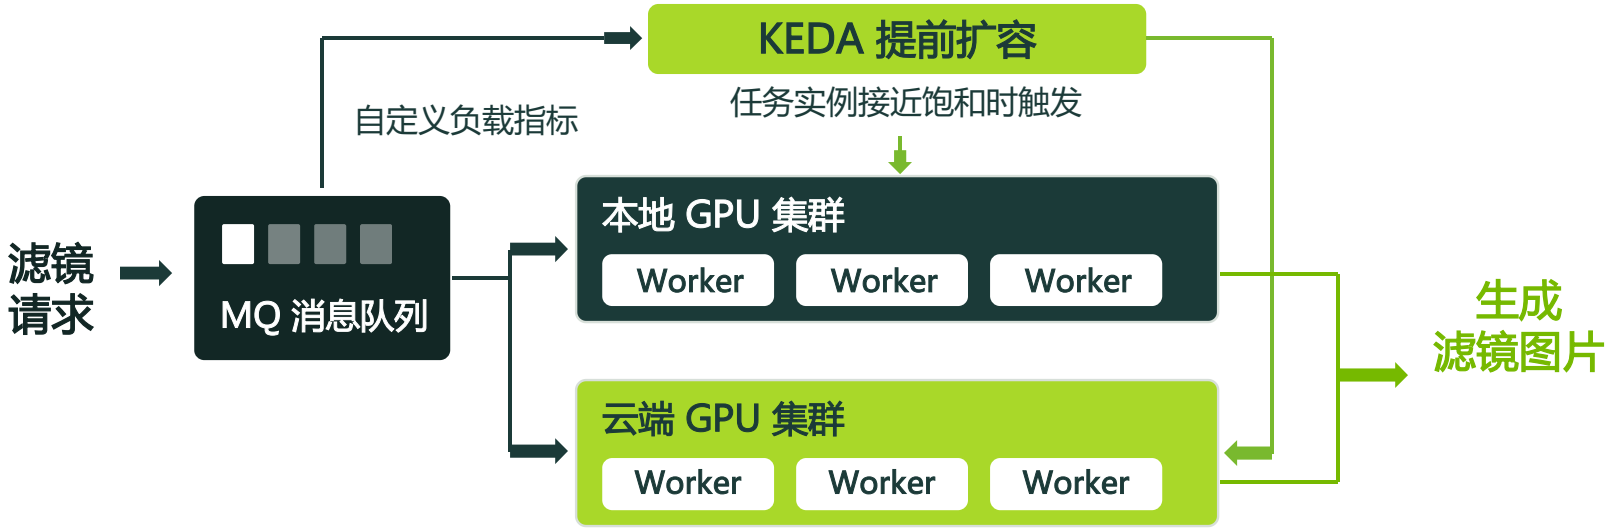
50%

训练与推理流水线 GPU 需求减少

1,000+ A100

支撑 1,200+ AI 工作流

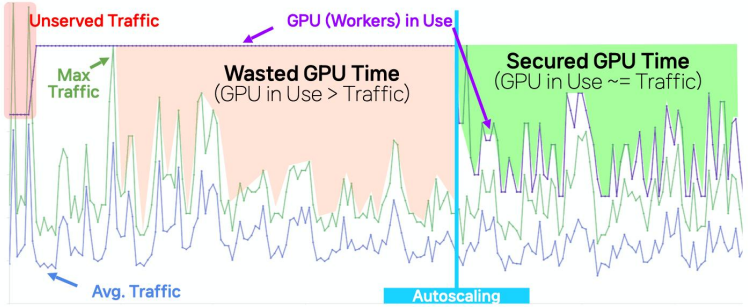
KEDA + HAMi：共享 GPU，随任务负载扩容



HAMi：训练—推理工作流共享同卡



主动伸缩：减少低谷时段 GPU 闲置



贝壳找房：训练整卡、推理细分

贝壳

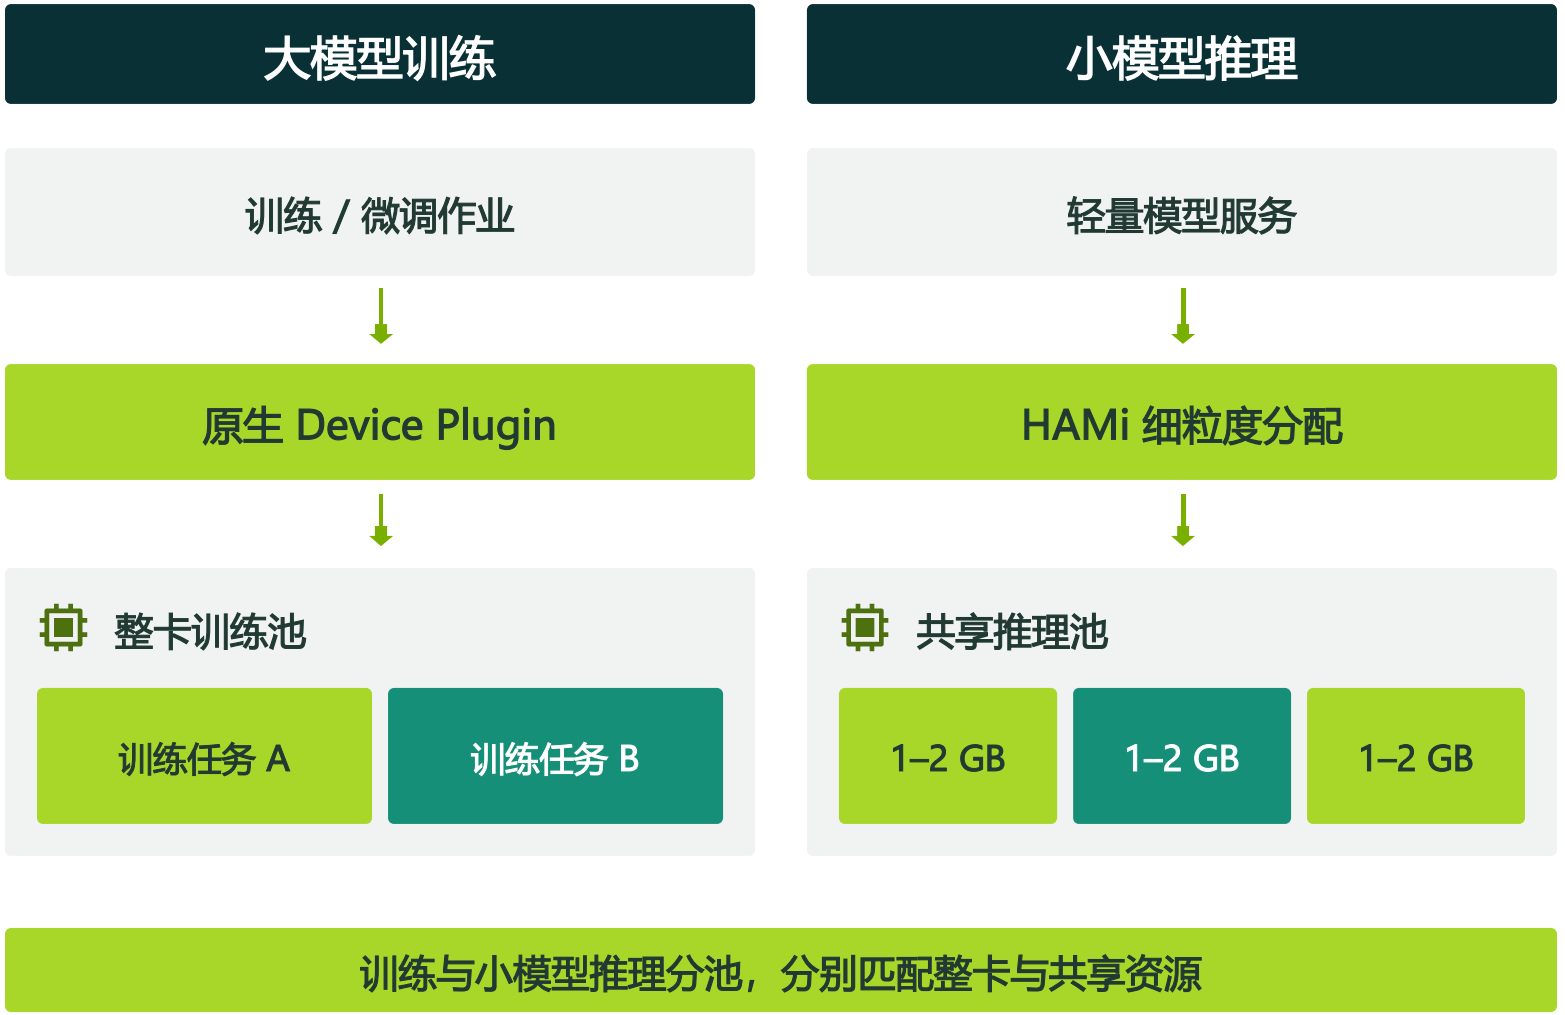
AIStudio 支撑训练与在线服务。训练池保留整卡，小模型推理池使用 HAMi 按显存分配资源，让不同负载匹配各自的用卡方式。

13% → 37%

平台 GPU 利用率

10,000+ Pods

平台并发运行规模



深信服：多模型共享推理资源

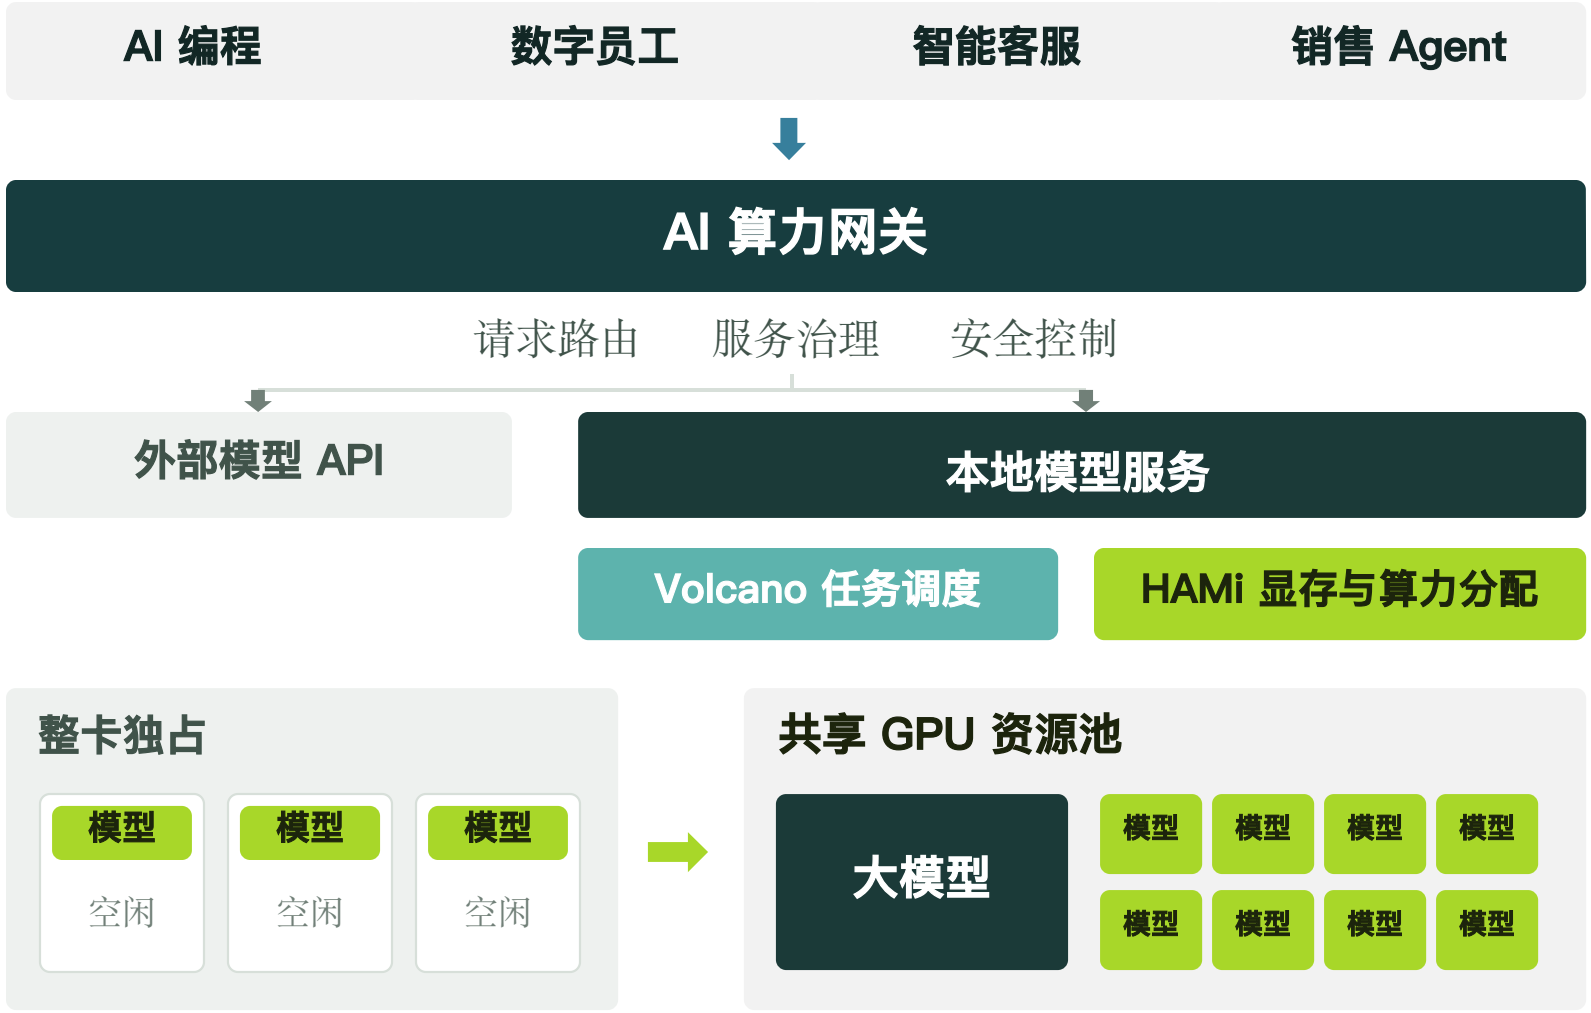
SANGFOR
深信服科技

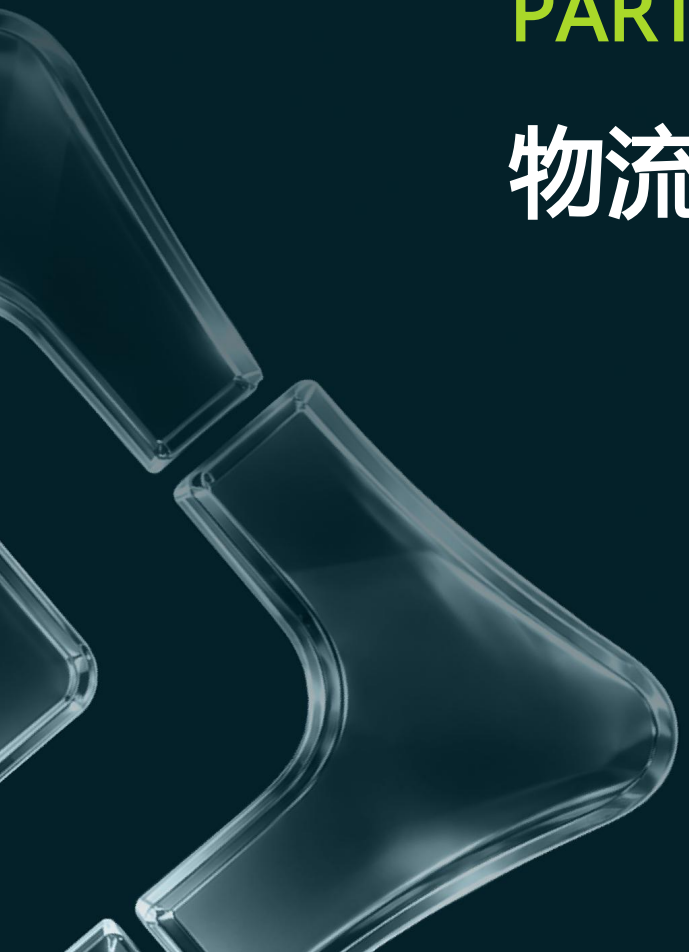
AI 编程、数字员工与客服
同时调用不同大小的模型。
统一网关承接请求，
Volcano 与 HAMi 协同调度，
让小模型按需共用 GPU。

1 → 8+
单卡小模型部署数量

提升 > 3 倍
GPU 利用率

2000+
服务研发人员数量





PART 05

物流

顺丰科技：生产模型服务资源池化

模型长期在线，却不需要整卡。顺丰基于 HAMi 构建 EffectiveGPU，将异构设备纳入资源池，按模型需求选择独占、切分与共享。

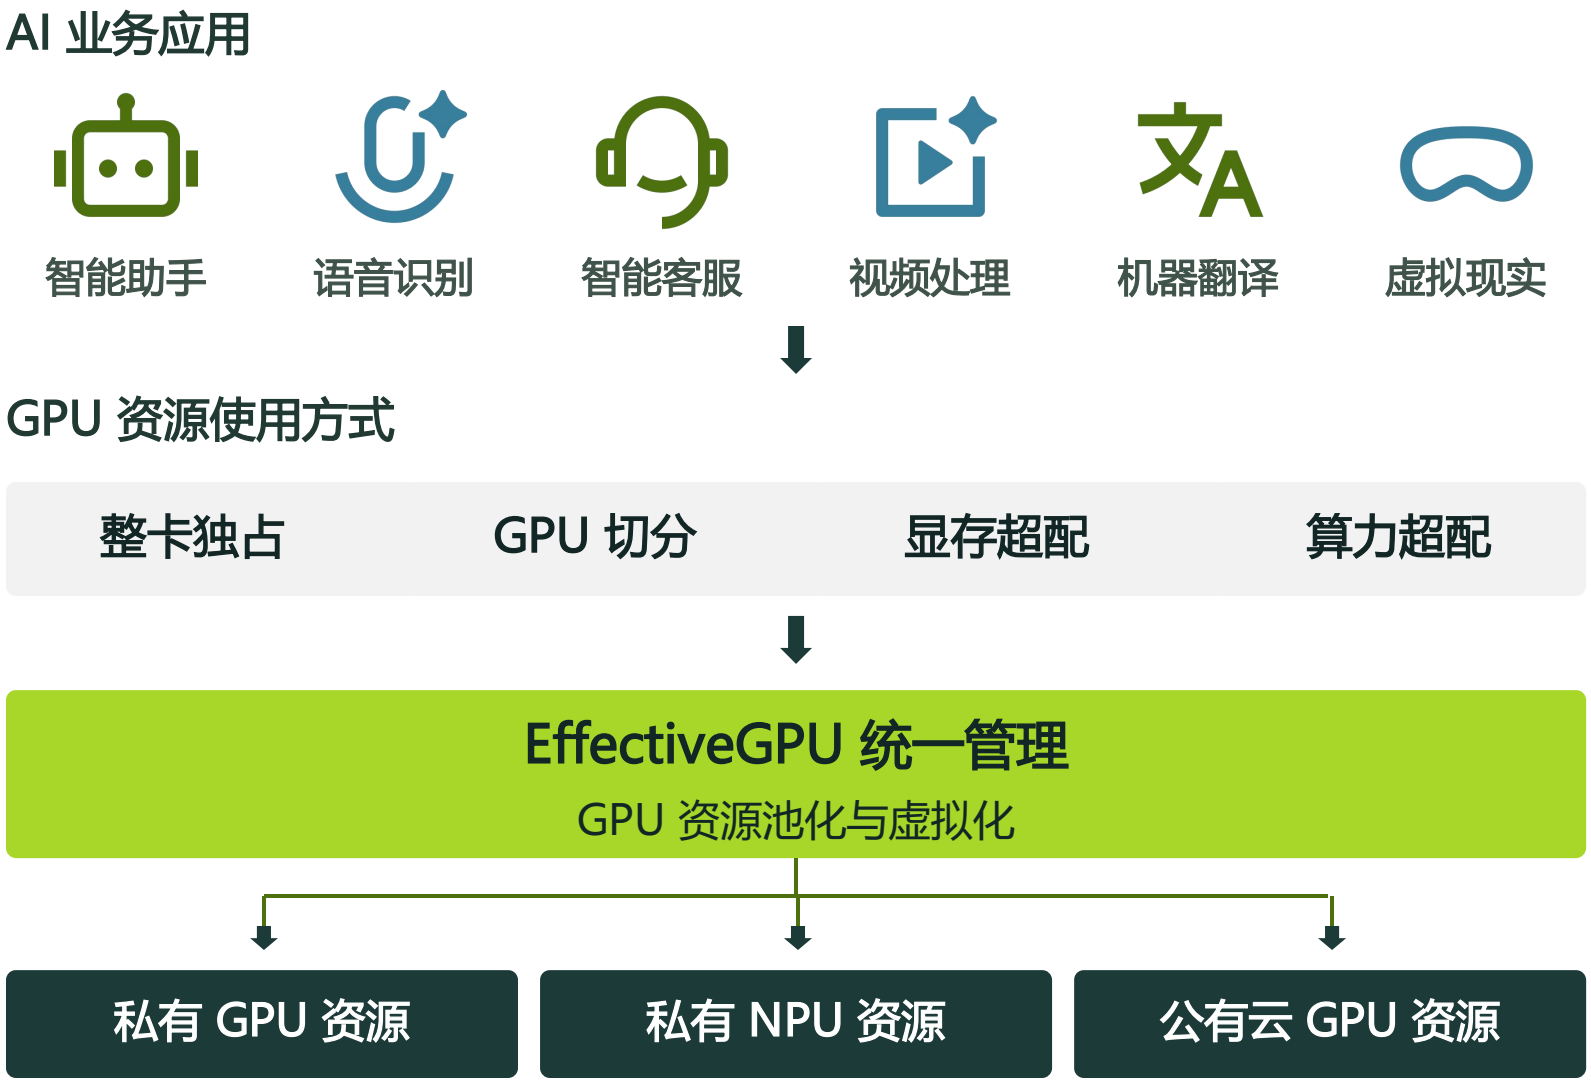
生产集群

65 个服务 / 28 张卡

（GPU 资源最高节省 57%）

测试集群

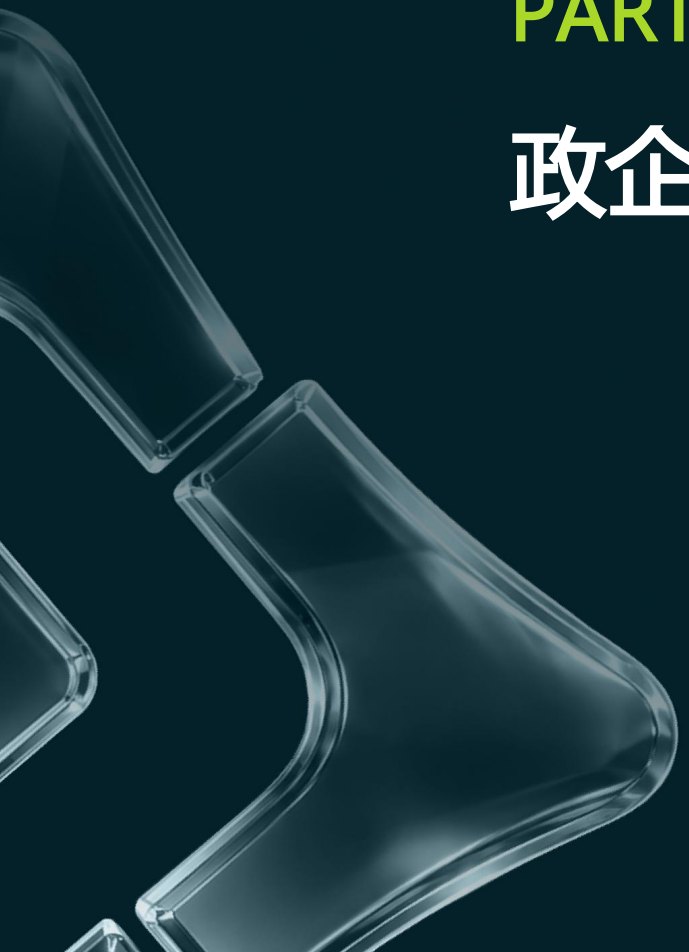
19 个服务 / 6 张卡



密瓜智能 DYNAMIA.AI | HAMi

PART 06

政企 / 能源 / 电力



某电网集团：总部算力支撑多地业务

某电网集团

总部建设算力平台，各地州拥有独立的 AI 组件与业务需求。通过统一入口管理组件、配额和用量，减少重复采购与资源协调。

200 个

AI 组件集中纳管

统一入口

连接地州需求与总部算力



云南电网：巡检训练与推理一池管理

云南电网

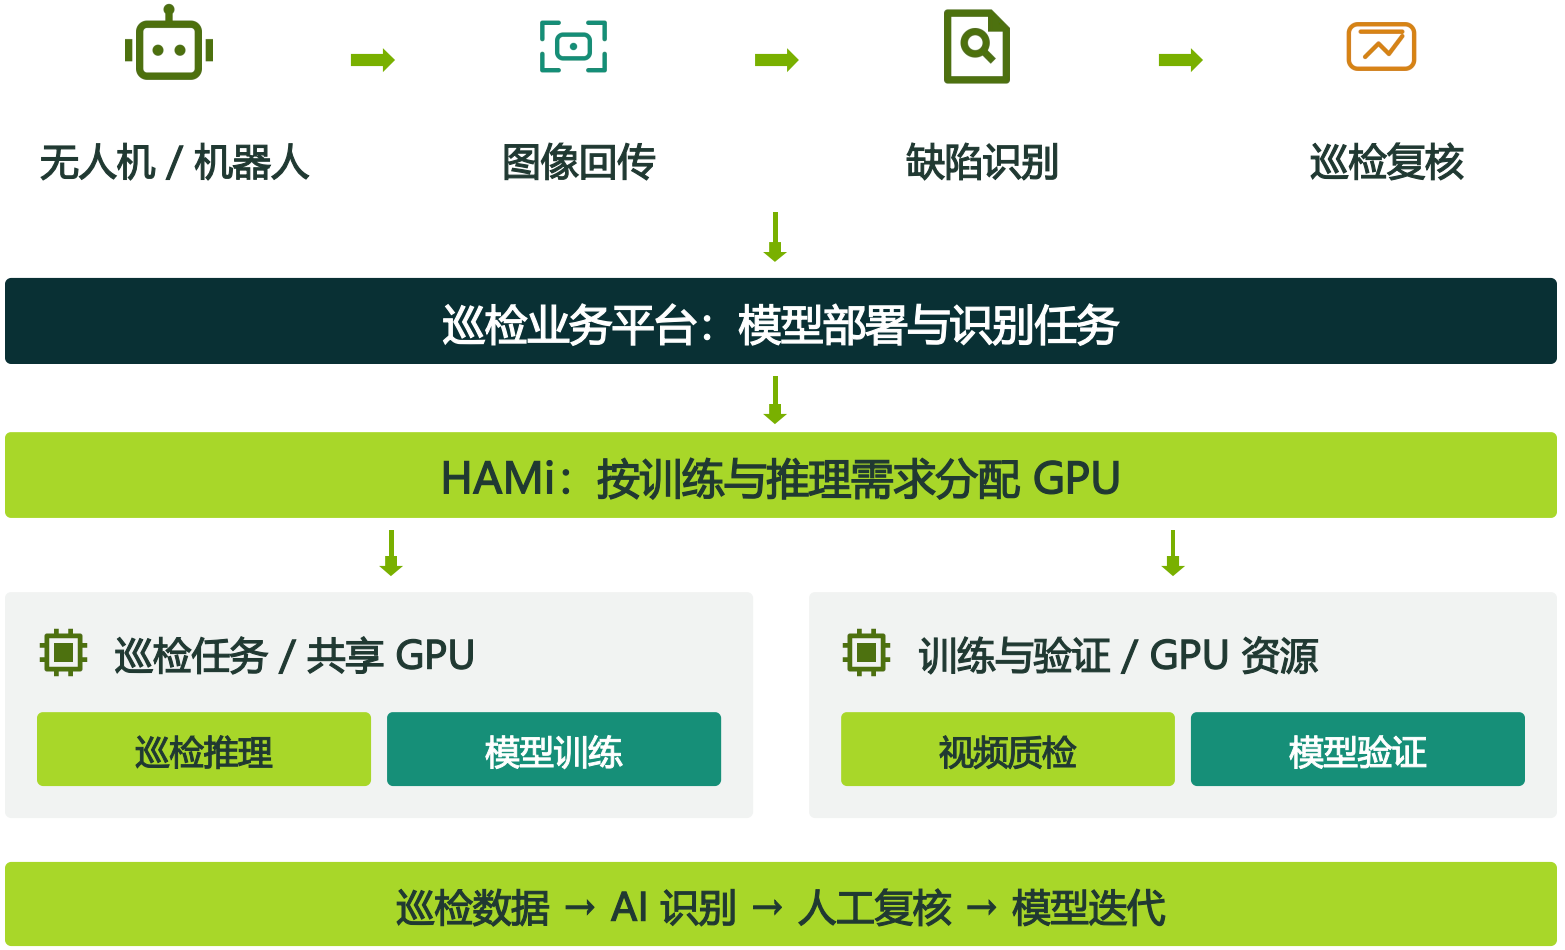
无人机和机器人回传巡检图像，模型识别设备缺陷，再由人员复核。统一管理总部与地州资源，支持巡检推理和模型迭代。

多地州资源

存量 GPU 统一纳管

训练 + 推理

让不同阶段复用算力供给



某电信运营商：异构设备统一接入

某电信运营商

不同服务器、加速设备和边缘终端共同支撑识别与质检。业务通过平台选择模型、申请资源，适配层匹配兼容设备并组织任务运行。

1,000+ GPU

交流材料记录的管理规模

统一资源接口

适配差异集中在平台处理



中电科云：一体机同时服务生产与研发

CETC 中国电科

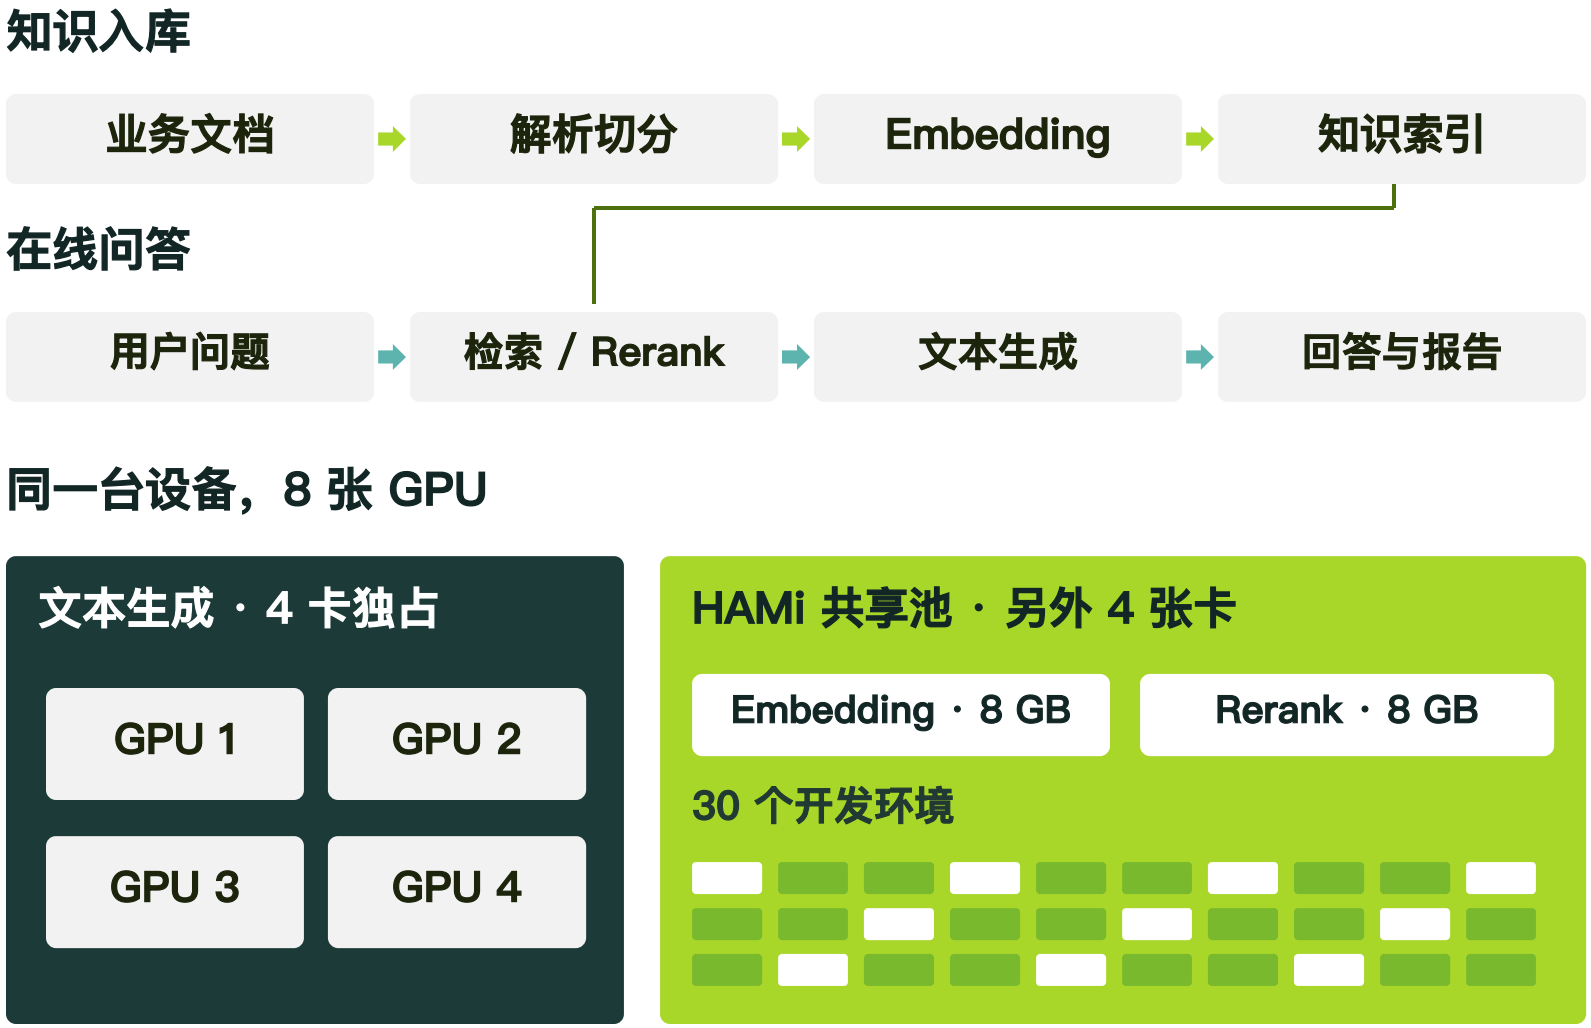
现场知识库需要稳定回答问题，
开发人员也需要调试环境。
保留生成模型的整卡资源，
将小模型改为按需分配，
剩余资源继续承载研发。

×15倍

并发开发 Pod 的数量

87.5%

显存回收率



庆阳：算力中心运营方案测算

庆阳算力方案

在算力中心规划中，先核算存量设备的有效产出，再比较提效与扩容投入。用相同业务算量，测算利用率提升对所需卡数的影响。

20% → 50%

测算中的利用率假设

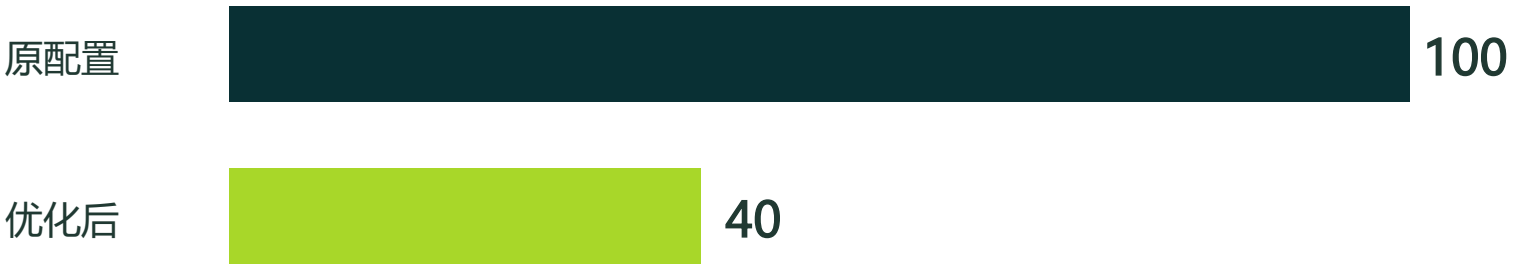
60%

同等算量下的理论卡数减少

先提高有效产出，再决定扩容规模

利用率假设　20% → 50%

同等业务算量所需卡数（指数）



40 = 100 × 20% ÷ 50%

情景测算：业务算量与单卡能力不变，不代表已交付实绩



PART 07

云厂商 / 算力云

基石智算：从整卡售卖到小规格租用

基石智算
CoresHub

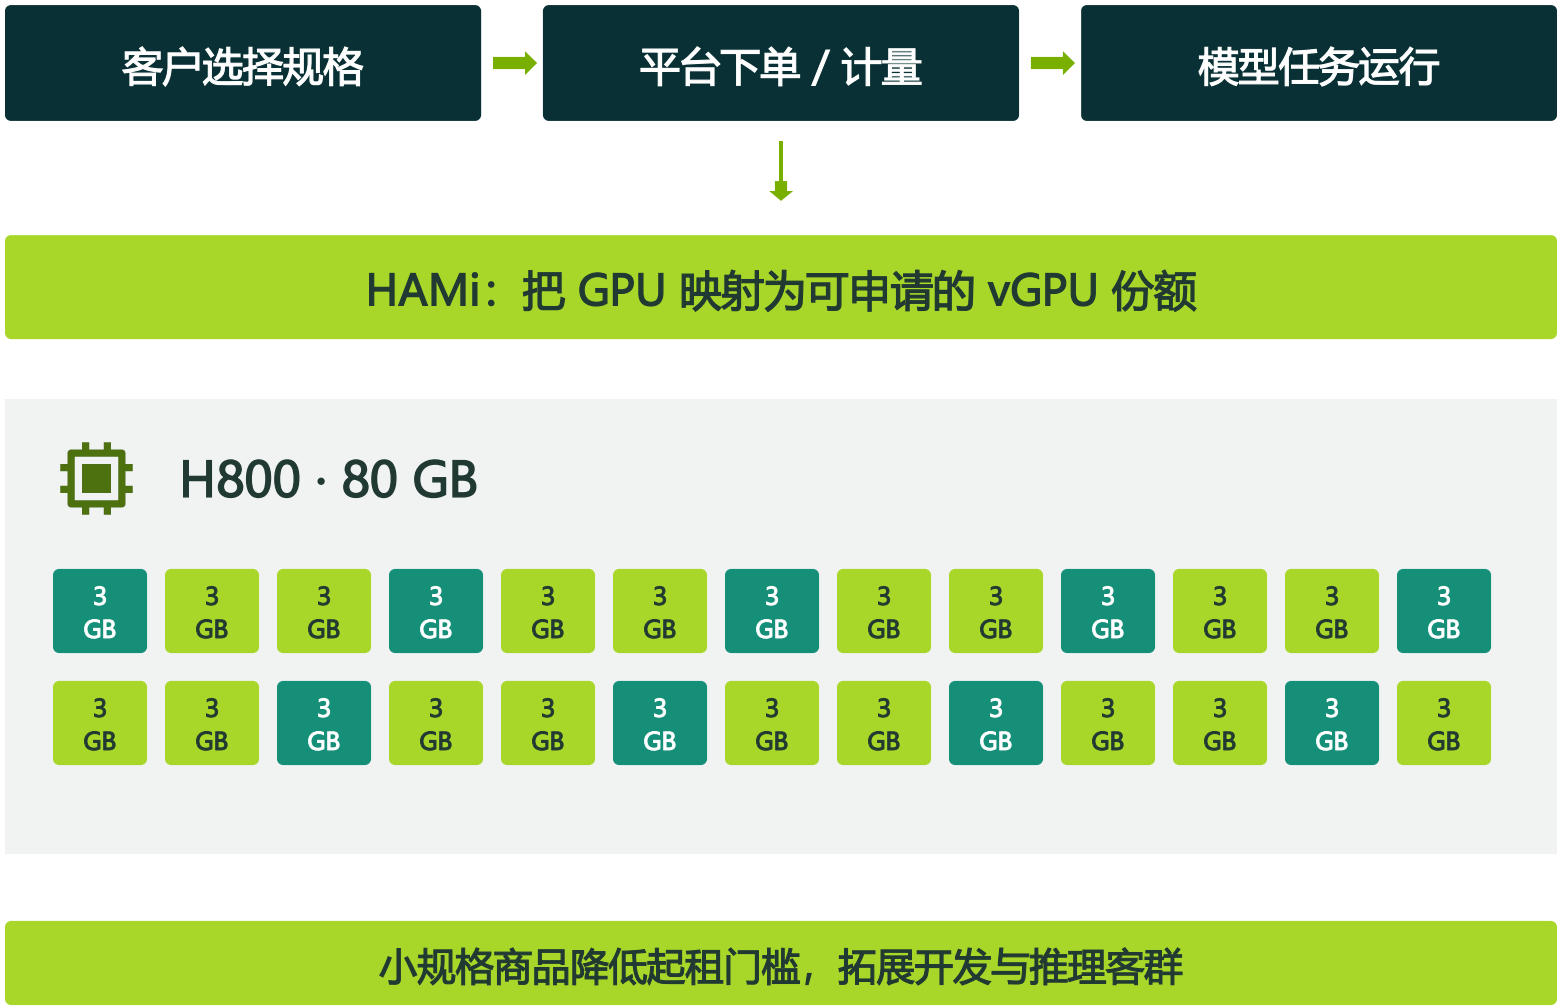
小模型开发与推理通常只需部分显存。把 H800 切分为可租用的小规格 vGPU，配合商品目录、计量与订单管理，降低起租门槛。

3 GB 起租

既有案例中的 vGPU 规格

26 份 / 单卡

80 GB 卡按 3 GB 规格的容量示例



DaoCloud：公有 GPU 云与企业共享池

DaoCloud

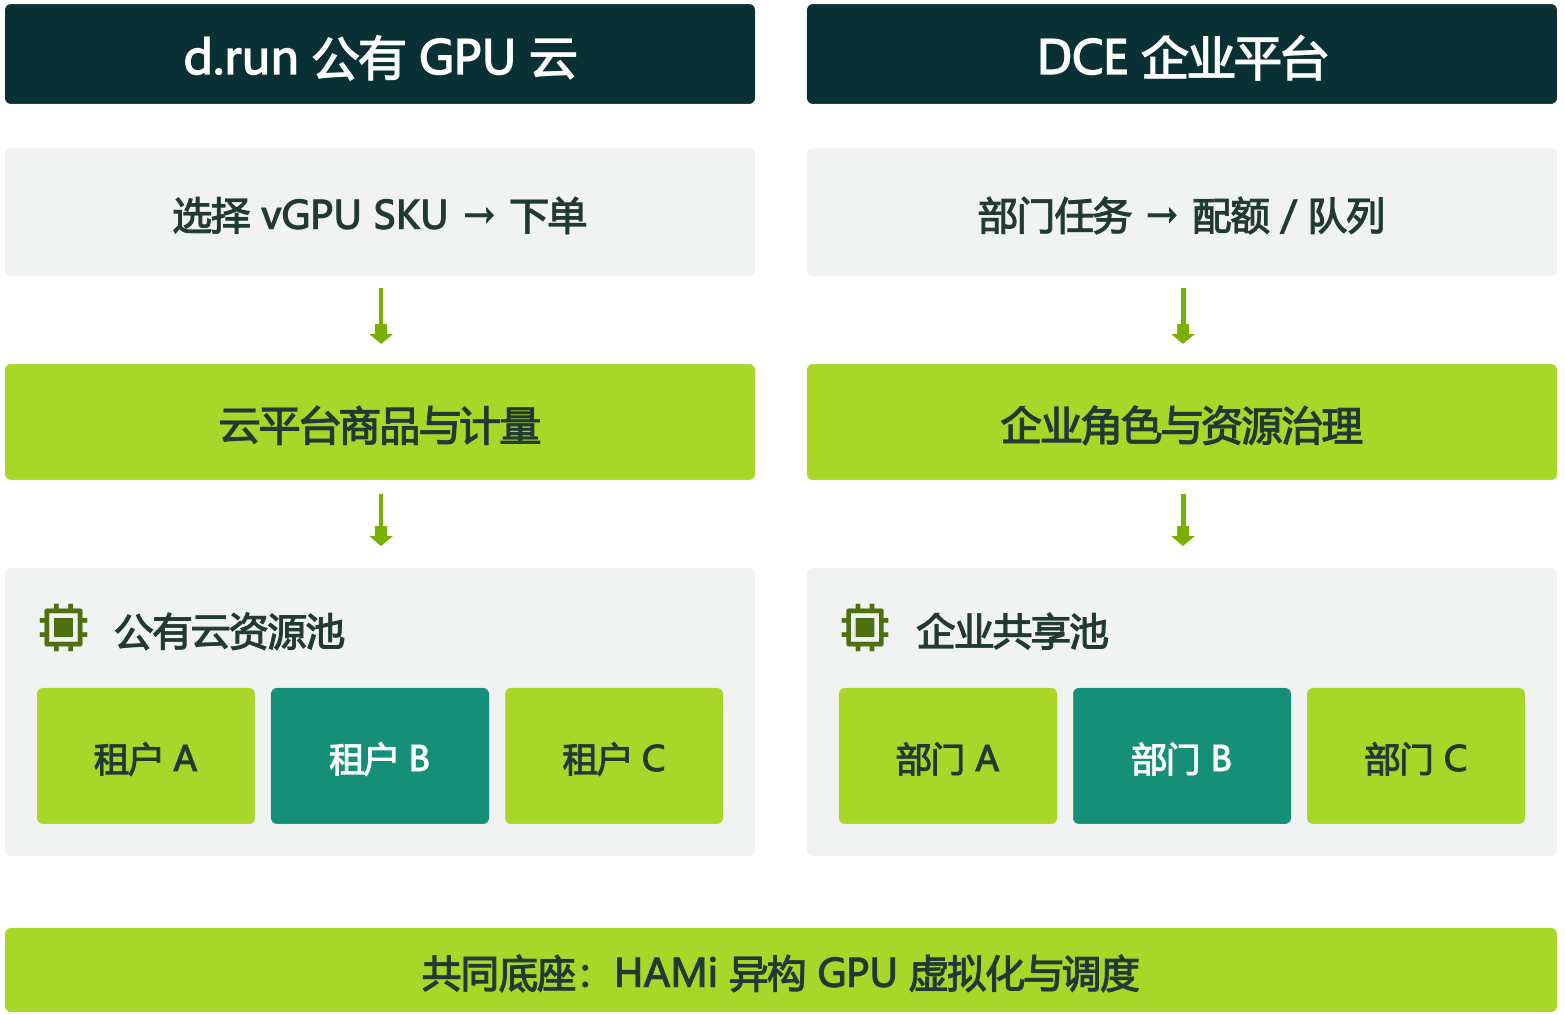
d.run 面向开发者提供 GPU 商品，DCE 面向企业提供多租户共享池。共同采用 HAMi 虚拟化与调度，分别衔接商品计量与企业资源治理。

>80%

采用 vGPU 后的平均 GPU 利用率

下降 20%–30%

GPU 相关运营成本



UCloud：把共享算力交付为开发环境

UCLOUD 优刻得

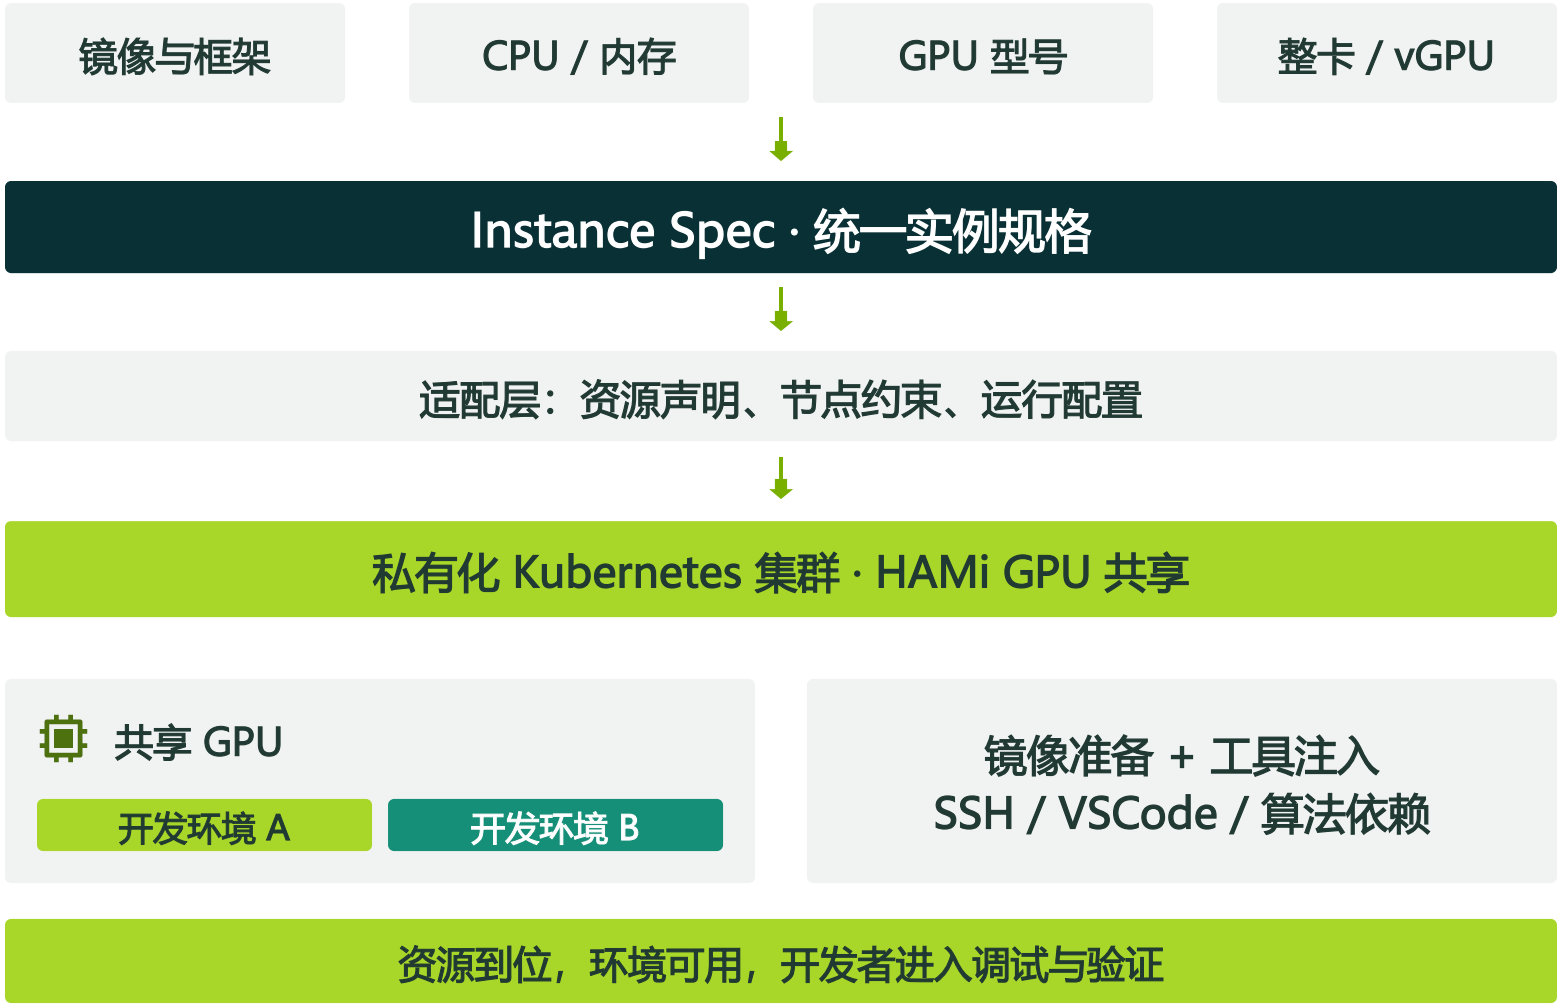
开发者需要可用的 GPU、镜像、框架和工具。统一实例规格，经适配层申请资源，再装配开发环境；私有化场景通过 HAMi 共享 GPU。

整卡 / vGPU

进入统一实例规格

环境交付

资源、镜像与工具协同准备



密瓜智能 DYNAMIA.AI | HAMi

欢迎关注
Follow Us

免费试用

社区入口

HAMi Github

info@dynamia.ai

@dynamia_ai

https://github.com/Project-HAMi/HAMi